

Problema de Machine Learning de Regressão: Previsão de tráfego futuro

1 - Definindo o problema de negócio

Este conjunto de dados inclui informações sobre o volume de tráfego em determinadas estradas ao longo do tempo, juntamente com características como clima e feriados, e o objetivo é prever o volume de tráfego futuro.

2 - Decisões

O problema de negócio já informa que é requerido um modelo de Machine Learning. No dataset, temos a coluna "traffic_volume" que é a variável que queremos prever. Desta forma, iremos utilizar aprendizagem supervisionada.

3 - Versão python e import dos pacotes utilizados

```
In [1]: # Versão da Linguagem Python
from platform import python_version
print('Versão da Linguagem Python Usada Neste Jupyter Notebook:', python_version())
```

Versão da Linguagem Python Usada Neste Jupyter Notebook: 3.9.13

```
In [2]: # Para atualizar um pacote, execute o comando abaixo no terminal ou prompt de comando
# pip install -U nome_pacote

# Para instalar a versão exata de um pacote, execute o comando abaixo no terminal ou prompt de comando
#!pip install nome_pacote==versão_desejada

# Depois de instalar ou atualizar o pacote, reinicie o jupyter notebook.

# Instala o pacote watermark.
# Esse pacote é usado para gravar as versões de outros pacotes usados neste jupyter notebook
#!pip install -q -U watermark
```

```
In [3]: #!pip install keras==2.13.1
#!pip install tensorflow==2.13.0
#!pip install --upgrade tensorflow
```

```
In [4]: # Imports
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
sns.set_style('whitegrid')
```

```

import sklearn
import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense, TimeDistributed, Conv1D, MaxPooling1D
from sklearn.preprocessing import LabelEncoder
from pmdarima.arima import auto_arima
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import train_test_split
from sklearn.feature_selection import RFE
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import Ridge
from sklearn.linear_model import Lasso
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.tsa.stattools import adfuller
from sklearn.ensemble import RandomForestRegressor
from sklearn.ensemble import GradientBoostingRegressor
from statsmodels.tsa.arima.model import ARIMA
from sklearn.neural_network import MLPRegressor
from xgboost import XGBRegressor
from lightgbm import LGBMRegressor
from sklearn.metrics import explained_variance_score, mean_absolute_error, mean_squared_error
%matplotlib inline
import warnings
warnings.filterwarnings("ignore", category=FutureWarning)

```

```

In [5]: # Versões dos pacotes usados neste jupyter notebook
%reload_ext watermark
%watermark -a "Danilo Temerloglou de Abreu" --iversions

```

Author: Danilo Temerloglou de Abreu

```

pandas      : 1.3.4
seaborn     : 0.12.2
sklearn     : 1.2.1
matplotlib: 3.7.1
numpy       : 1.23.5
tensorflow: 2.16.1

```

4 - Dicionário de dados

```

In [6]: #holiday - Feriados nacionais dos USA mais feriados regionais, Feira Estadual de Miami
#temp - Temperatura média em Kelvin
#rain_1h - Quantidade em mm de chuva que ocorreu na hora
#snow_1h - Quantidade em mm de neve que ocorreu na hora
#clouds_all - Porcentagem de cobertura de nuvens
#weather_main - Breve descrição textual do clima atual
#weather_description - Descrição textual mais longa do clima atual
#date_time - Hora dos dados coletados no horário Local CST
#traffic_volume - Volume de tráfego no sentido oeste relatado por hora I-94 ATR 301

```

5 - Carregando o Conjunto de dados

```
In [7]: # Carrega o dataset
df = pd.read_csv('Metro_Interstate_Traffic_Volume.csv')
```

6 - EDA Análise Exploratória de Dados

```
In [8]: # Shape
df.shape
```

```
Out[8]: (48204, 9)
```

```
In [9]: #nomes das colunas
df.columns
```

```
Out[9]: Index(['holiday', 'temp', 'rain_1h', 'snow_1h', 'clouds_all', 'weather_main',
              'weather_description', 'date_time', 'traffic_volume'],
              dtype='object')
```

```
In [10]: # Info
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 48204 entries, 0 to 48203
Data columns (total 9 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   holiday                48204 non-null object  
 1   temp                  48204 non-null float64
 2   rain_1h               48204 non-null float64
 3   snow_1h               48204 non-null float64
 4   clouds_all            48204 non-null int64  
 5   weather_main          48204 non-null object  
 6   weather_description    48204 non-null object  
 7   date_time              48204 non-null object  
 8   traffic_volume         48204 non-null int64  
dtypes: float64(3), int64(2), object(4)
memory usage: 3.3+ MB
```

```
In [11]: # Amostra
df.sample(5)
```

07/06/2024, 13:06Projeto_prev_trafego

Out[11]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	date_time
42418	None	268.69	0.0	0.0	1	Clear	sky is clear	2018-03-1 04:00:00
39627	None	266.50	0.0	0.0	75	Snow	light snow	2017-12-0 12:00:00
7169	None	295.20	0.0	0.0	90	Thunderstorm	proximity thunderstorm with rain	2013-06-2 05:00:00
17206	None	292.53	0.0	0.0	90	Clouds	overcast clouds	2015-08-0 08:00:00
42838	None	266.61	0.0	0.0	1	Clear	sky is clear	2018-03-0 04:00:00

Exploração das variáveis numéricas

In [12]:

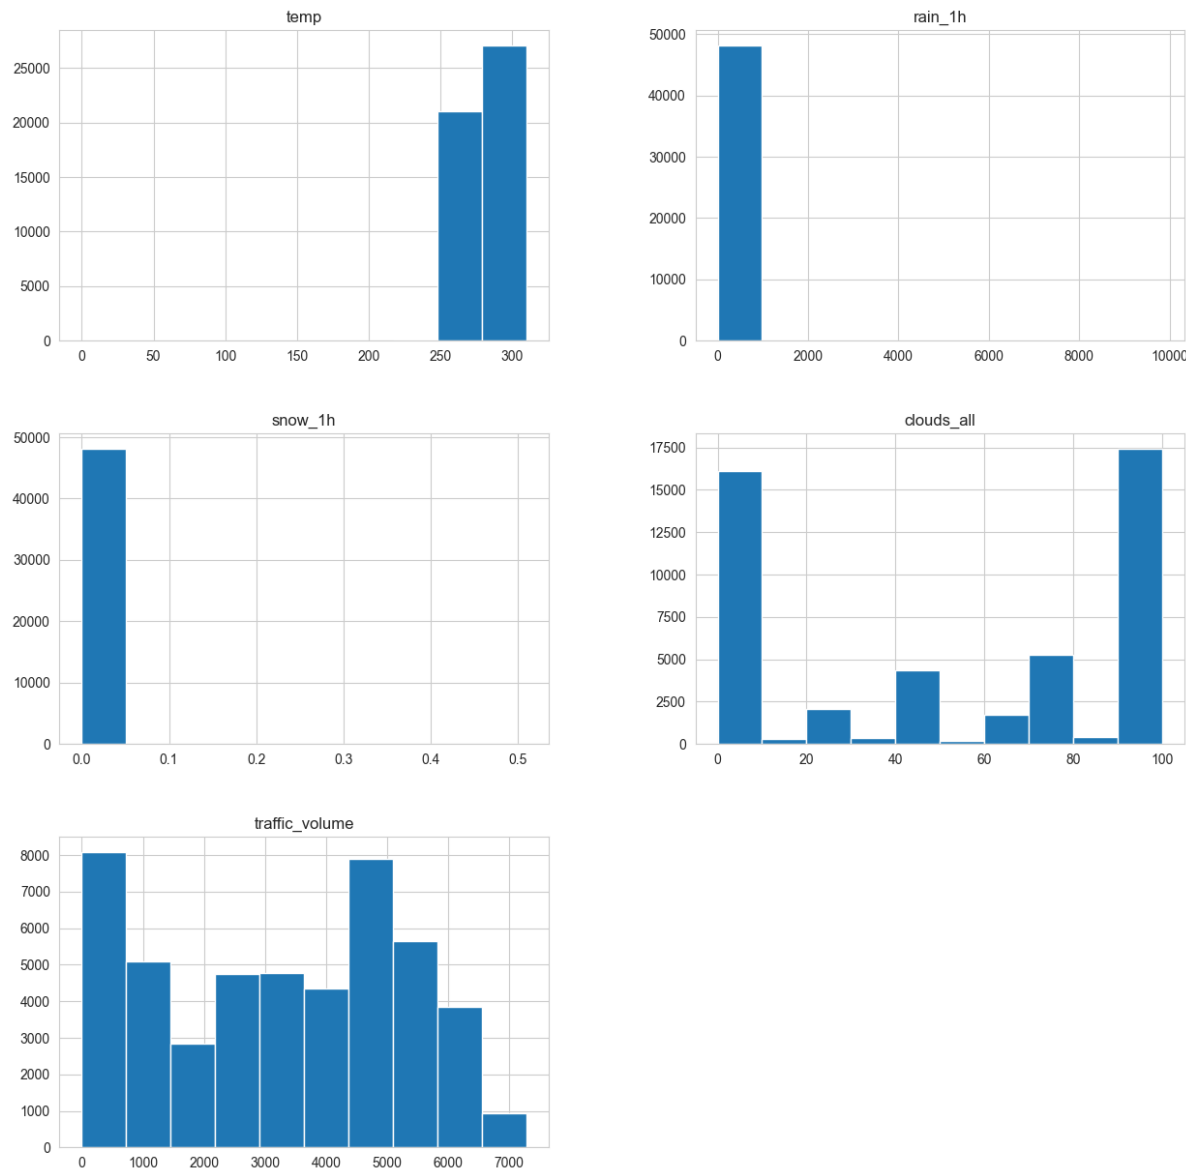
df.describe()

Out[12]:

	temp	rain_1h	snow_1h	clouds_all	traffic_volume
count	48204.000000	48204.000000	48204.000000	48204.000000	48204.000000
mean	281.205870	0.334264	0.000222	49.362231	3259.818355
std	13.338232	44.789133	0.008168	39.015750	1986.860670
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	272.160000	0.000000	0.000000	1.000000	1193.000000
50%	282.450000	0.000000	0.000000	64.000000	3380.000000
75%	291.806000	0.000000	0.000000	90.000000	4933.000000
max	310.070000	9831.300000	0.510000	100.000000	7280.000000

In [13]:

Plot
df.hist(figsize = (15,15), bins = 10)
plt.show()



```
In [14]: # Insights:
# temperaturas concentram-se de 250 a 300K = -23 a 26 °C
# média baixa de chuva e de neve durante 1 hora
# maioria dos dados está com tempo aberto ou nublado
# volume de tráfego está com boa variedade de valores
```

```
In [15]: # Correlação (tabela)
df.corr()
```

Out[15]:

	temp	rain_1h	snow_1h	clouds_all	traffic_volume
temp	1.000000	0.009069	-0.019755	-0.101976	0.130299
rain_1h	0.009069	1.000000	-0.000090	0.004818	0.004714
snow_1h	-0.019755	-0.000090	1.000000	0.027931	0.000733
clouds_all	-0.101976	0.004818	0.027931	1.000000	0.067054
traffic_volume	0.130299	0.004714	0.000733	0.067054	1.000000


```
In [16]: #A variável traffic_volume (que é a que queremos prever) tem baixa correlação com a
# As variáveis predictoras numéricas tem baixa correlação entre si o que é bom para
```

Exploração das variáveis categóricas

```
In [17]: df['holiday'].value_counts()
```

```
Out[17]: None          48143
Labor Day          7
Thanksgiving Day   6
Christmas Day       6
New Years Day       6
Martin Luther King Jr Day  6
Columbus Day        5
Veterans Day        5
Washingtons Birthday 5
Memorial Day        5
Independence Day    5
State Fair          5
Name: holiday, dtype: int64
```

```
In [18]: ax = sns.countplot(data=df, x='holiday', order=df['holiday'].value_counts().index)
ax.set_xticklabels(ax.get_xticklabels(), rotation=45, ha='right')
plt.show()
```



```
In [19]: quantidade_de_categorias_holiday = df['holiday'].nunique()
print("Quantidade de categorias de feriados:", quantidade_de_categorias_holiday)
```


Quantidade de categorias de feriados: 12

```
In [20]: # grande maioria de dias não é feriado
```

```
In [21]: df['weather_main'].value_counts()
```

```
Out[21]: Clouds      15164
Clear      13391
Mist       5950
Rain       5672
Snow       2876
Drizzle    1821
Haze       1360
Thunderstorm 1034
Fog        912
Smoke      20
Squall     4
Name: weather_main, dtype: int64
```

```
In [22]: ax = sns.countplot(data=df, x='weather_main', order=df['weather_main'].value_counts)
ax.set_xticklabels(ax.get_xticklabels(), rotation=45, ha='right')
plt.show()
```



```
In [23]: # maioria dos dados está com tempo aberto ou nublado
```


```
In [24]: quantidade_de_categorias_weather_main = df['weather_main'].nunique()
print("Quantidade de categorias de tempo_resumo:", quantidade_de_categorias_weather_main)

Quantidade de categorias de tempo_resumo: 11
```

```
In [25]: df['weather_description'].value_counts()
```

```
Out[25]: sky is clear      11665
mist      5950
overcast clouds      5081
broken clouds      4666
scattered clouds      3461
light rain      3372
few clouds      1956
light snow      1946
Sky is Clear      1726
moderate rain      1664
haze      1360
light intensity drizzle      1100
fog      912
proximity thunderstorm      673
drizzle      651
heavy snow      616
heavy intensity rain      467
snow      293
proximity shower rain      136
thunderstorm      125
heavy intensity drizzle      64
thunderstorm with heavy rain      63
thunderstorm with light rain      54
proximity thunderstorm with rain      52
thunderstorm with rain      37
smoke      20
very heavy rain      18
thunderstorm with light drizzle      15
light intensity shower rain      13
proximity thunderstorm with drizzle      13
light shower snow      11
light rain and snow      6
shower drizzle      6
SQUALLS      4
sleet      3
thunderstorm with drizzle      2
freezing rain      2
shower snow      1
Name: weather_description, dtype: int64
```

```
In [26]: ax = sns.countplot(data=df, y='weather_description', orient='h', order=df['weather_
plt.show()
```




```
In [27]: # maioria dos dados está com tempo aberto ou nublado

In [28]: quantidade_de_categorias_weather_description = df['weather_description'].nunique()
print("Quantidade de categorias de tempo_resumo:", quantidade_de_categorias_weather

Quantidade de categorias de tempo_resumo: 38
```

Tratando a variável date_time

```
In [29]: #converte variável date_time para tipo datetime
df['date_time'] = pd.to_datetime(df['date_time'], format='%Y-%m-%d %H:%M:%S')

In [30]: #verifica tipo
df['date_time'].dtypes

Out[30]: dtype('<M8[ns]')

In [31]: #cria duas variáveis 'data' e 'hora'
df['data'] = df['date_time'].dt.date
df['hora_completa'] = df['date_time'].dt.time
#exclui a coluna 'date_time'
df = df.drop(columns=['date_time'])

In [32]: df.sample(5)
```

Out[32]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_v
29636	None	266.51	0.00	0.0	1	Clear	sky is clear	
10525	None	260.50	0.25	0.0	64	Snow	light snow	
11951	None	0.00	0.00	0.0	0	Clear	sky is clear	
36382	None	288.01	0.00	0.0	1	Clear	sky is clear	
43185	None	277.15	0.00	0.0	90	Rain	light rain	

```
In [33]: print(df.dtypes)

holiday                object
temp                  float64
rain_1h               float64
snow_1h              float64
clouds_all             int64
weather_main          object
weather_description    object
traffic_volume         int64
data                  object
hora_completa          object
dtype: object
```

```
In [34]: df.shape

Out[34]: (48204, 10)
```

```
In [35]: #converte a data e obriga o que estiver em formato errado a ficar como NaT (not a time)
df['data'] = pd.to_datetime(df['data'], errors='coerce')
# Exclua as Linhas com valores NaT na coluna 'data' e 'hora'
df = df.dropna(subset=['data'])
```

```
In [36]: df.shape
```

```
Out[36]: (48204, 10)
```

```
In [37]: df.sample(5)
```

```
Out[37]:
```

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_volume
1344	None	273.99	0.0	0.0	1	Mist	mist	
16968	None	292.84	0.0	0.0	1	Clear	sky is clear	
33320	None	280.65	0.0	0.0	75	Clouds	broken clouds	
33408	None	292.46	0.0	0.0	40	Clouds	scattered clouds	
6324	None	280.66	0.0	0.0	90	Mist	mist	

```
In [38]: #problemas de formato na coluna 'hora_completa'
print(df['hora_completa'].unique())

[datetime.time(9, 0) datetime.time(10, 0) datetime.time(11, 0)
datetime.time(12, 0) datetime.time(13, 0) datetime.time(14, 0)
datetime.time(15, 0) datetime.time(16, 0) datetime.time(17, 0)
datetime.time(18, 0) datetime.time(19, 0) datetime.time(20, 0)
datetime.time(21, 0) datetime.time(22, 0) datetime.time(23, 0)
datetime.time(0, 0) datetime.time(1, 0) datetime.time(2, 0)
datetime.time(3, 0) datetime.time(4, 0) datetime.time(5, 0)
datetime.time(6, 0) datetime.time(8, 0) datetime.time(7, 0)]
```

```
In [39]: # Converte a coluna de datetime.time para uma string formatada
df['hora_completa'] = df['hora_completa'].astype(str)
# Extrai os dois primeiros dígitos de cada valor na coluna
df['apenas_hora'] = df['hora_completa'].str[:2]
```

```
In [40]: df.shape
```

```
Out[40]: (48204, 11)
```

```
In [41]: df.sample(5)
```

Out[41]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_v
35202	None	298.29	0.0	0.0	75	Thunderstorm	proximity thunderstorm	
44776	None	291.15	0.0	0.0	1	Rain	moderate rain	
48014	None	296.90	0.0	0.0	40	Clouds	scattered clouds	
342	None	288.86	0.0	0.0	75	Clouds	broken clouds	
33753	None	284.79	0.0	0.0	90	Rain	heavy intensity rain	



In [42]:

```
#exclui a coluna 'hora_completa'  
df = df.drop(columns=['hora_completa'])
```

In [43]:

```
df.sample(5)
```

Out[43]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_v
32973	None	287.69	0.00	0.0	1	Clear	sky is clear	
7036	None	292.85	1.52	0.0	88	Rain	moderate rain	
23430	None	280.01	0.00	0.0	1	Clear	sky is clear	
33177	None	285.48	0.00	0.0	1	Clear	sky is clear	
34947	None	295.77	0.00	0.0	90	Clouds	overcast clouds	



In [44]:

```
#alterar a coluna 'data' para formato 'dia-mês-ano'  
df['data'] = df['data'].dt.strftime('%d-%m-%Y')
```

In [45]:

```
df.sample(5)
```

Out[45]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_vo
23585	None	290.99	0.0	0.0	40	Thunderstorm	proximity thunderstorm	
41872	None	270.00	0.0	0.0	20	Clouds	few clouds	
45508	None	301.65	0.0	0.0	40	Clouds	scattered clouds	
5794	None	281.05	0.0	0.0	90	Clouds	overcast clouds	
19374	None	278.15	0.0	0.0	5	Clear	sky is clear	



In [46]:

```
#mudando 'data' para tipo 'datetime'  
df['data'] = pd.to_datetime(df['data'])  
#criando as variáveis 'dia', 'mes', 'ano'  
df['dia'] = df['data'].dt.day  
df['mes'] = df['data'].dt.month  
df['ano'] = df['data'].dt.year
```

In [47]:

```
print(df.dtypes)  
  
holiday                object  
temp                  float64  
rain_1h               float64  
snow_1h              float64  
clouds_all            int64  
weather_main          object  
weather_description    object  
traffic_volume        int64  
data                  datetime64[ns]  
apenas_hora           object  
dia                   int64  
mes                   int64  
ano                   int64  
dtype: object
```

In [48]:

```
df.sample(5)
```

Out[48]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_vo
--	---------	------	---------	---------	------------	--------------	---------------------	------------

8212	None	290.16	0.00	0.0	92	Clouds	overcast clouds	
5868	None	293.30	0.00	0.0	40	Clouds	scattered clouds	
18350	None	295.86	1.52	0.0	90	Rain	moderate rain	
10320	None	274.59	0.00	0.0	64	Drizzle	drizzle	
25544	None	291.19	0.00	0.0	0	Clear	Sky is Clear	



```
In [49]: # Ordene o DataFrame por dia, mês e ano ao mesmo tempo em ordem crescente
df = df.sort_values(by=['ano', 'mes', 'dia', 'apenas_hora'])

# Se desejar, você pode redefinir o índice do DataFrame após a ordenação
df = df.reset_index(drop=True)
```

```
In [50]: df.head(5)
```

Out[50]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	traffic_volum
--	---------	------	---------	---------	------------	--------------	---------------------	---------------

0	None	271.73	0.0	0.0	1	Clear	sky is clear	71
1	None	270.91	0.0	0.0	1	Clear	sky is clear	45
2	None	270.15	0.0	0.0	1	Clear	sky is clear	32
3	None	269.68	0.0	0.0	1	Clear	sky is clear	39
4	None	269.44	0.0	0.0	1	Clear	sky is clear	77



```
In [51]: colunas_para_manter = [col for col in df.columns if col not in ['apenas_hora', 'traf
# Reorganizando a ordem das colunas
df = df[colunas_para_manter + ['apenas_hora', 'traffic_volume']]
```

```
In [52]: #mudando a coluna 'apenas_hora' para tipo int
df['apenas_hora'] = df['apenas_hora'].astype(int)
```

```
In [53]: df.sample(5)
```

Out[53]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	data	c
27822	None	256.65	0.00	0.0	90	Haze	haze	2016-11-01	
22424	None	295.68	0.28	0.0	92	Rain	light rain	2016-04-08	
12608	None	272.28	0.00	0.0	75	Clouds	broken clouds	2014-03-18	
7253	None	280.67	0.00	0.0	36	Clouds	scattered clouds	2013-07-10	
4478	None	267.88	0.00	0.0	40	Clouds	scattered clouds	2013-03-28	

In [54]:

```
# Ordene o DataFrame por dia, mês e ano ao mesmo tempo em ordem crescente
df = df.sort_values(by=['ano', 'mes', 'dia', 'apenas_hora'])

# Se desejar, você pode redefinir o índice do DataFrame após a ordenação
df = df.reset_index(drop=True)
```

In [55]:

```
df.head(10)
```

Out[55]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	data	dia	i
0	None	271.73	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
1	None	270.91	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
2	None	270.15	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
3	None	269.68	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
4	None	269.44	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
5	None	268.96	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
6	None	268.61	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
7	None	268.74	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	
8	None	268.45	0.0	0.0	20	Clouds	few clouds	2012-01-11	11	
9	None	270.90	0.0	0.0	1	Clear	sky is clear	2012-01-11	11	

In [56]:

```
#até aqui tenho o dataset df faltando tratar as variáveis categóricas holiday, weat
```

In [57]:


```
#gráfico da variável target que é o 'traffic_volume'
plt.plot(df['data'], df['traffic_volume'])
```

```
# Rotule os eixos
plt.xlabel('Data')
plt.ylabel('Volume de tráfego')

# Adicione um título ao gráfico
plt.title('Volume de tráfego ao Longo do Tempo')

# Rotacione os rótulos do eixo x para torná-los mais legíveis, se necessário
plt.xticks(rotation=45)

# Mostre o gráfico
plt.show()
```




```
In [58]: #visualização ficou muito ruim
#vamos agrupar os dados por mês e ano para melhorar a visualização
```

```
In [59]: # Crie uma coluna de data concatenando 'ano' e 'mes'
df['mes_ano'] = pd.to_datetime(df['mes'].astype(str) + '-' + df['ano'].astype(str),

# Agrupe os dados pela nova coluna de data e aplique a função de agregação desejada
dados_agrupados = df.groupby('mes_ano')['traffic_volume'].mean() # Por exemplo, co

# Plotar os dados agrupados
dados_agrupados.plot(kind='line', xlabel='Data', ylabel='Valor', title='Média do Tr
plt.show()
```

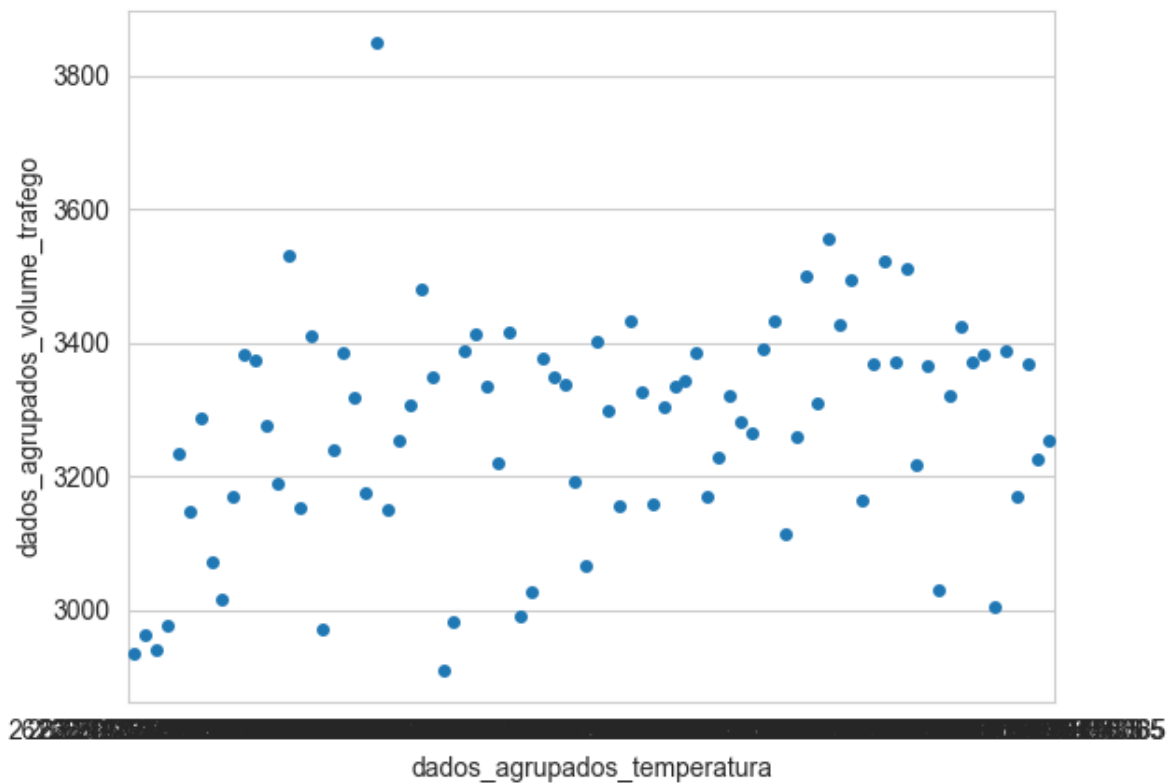


In [60]: *#vamos que de 2013 a 2019 ocorre uma sazonalidade sendo o meio do ano o período em*

Verificando a relação entre atributos

```
In [61]: # Agrupe os dados pela nova coluna de data e aplique a função de agregação desejada
dados_agrupados_temp = df.groupby('mes_ano')['temp'].mean()
# Plotar os dados agrupados
sns.stripplot(data=df, x=dados_agrupados_temp, y=dados_agrupados, jitter=True)
plt.xlabel('dados_agrupados_temperatura')
plt.ylabel('dados_agrupados_volume_trafego')
```

Out[61]: Text(0, 0.5, 'dados_agrupados_volume_trafego')



Observando o gráfico de dispersão verificamos que não há correlação entre a temperatura e o volume de tráfego.

7 - Pré-Processamento de Dados Para Construção de Modelos de Machine Learning

In [62]: `df.shape`

Out[62]: (48204, 14)

In [63]: `# Verificando valores ausentes`
`numero_ausentes = df.isnull().sum()`
`print('A quantidade de valores ausentes em cada coluna é:\n', numero_ausentes)`

A quantidade de valores ausentes em cada coluna é:

holiday	0
temp	0
rain_1h	0
snow_1h	0
clouds_all	0
weather_main	0
weather_description	0
data	0
dia	0
mes	0
ano	0
apenas_hora	0
traffic_volume	0
mes_ano	0

dtype: int64

In [64]: `# Verifica registros duplicados (remove uma das duplicatas)`
`numero_duplicados = df.duplicated().sum()`
`print('A quantidade de valores duplicados é: ', numero_duplicados)`


A quantidade de valores duplicados é: 17

```
In [65]: #remove valores duplicados  
df = df.drop_duplicates()
```

Tratamento de outliers


```
In [66]: # Boxplot  
sns.boxplot(df.temp)
```

Out[66]: <Axes: >




```
In [67]: # Boxplot  
sns.boxplot(df.rain_1h)
```

Out[67]: <Axes: >




```
In [68]: # Boxplot  
sns.boxplot(df.snow_1h)
```

```
Out[68]: <Axes: >
```




```
In [69]: # Boxplot  
sns.boxplot(df.clouds_all)
```

```
Out[69]: <Axes: >
```



```
In [70]: # Boxplot
sns.boxplot(df.traffic_volume)
```

```
Out[70]: <Axes: >
```



```
In [71]: #outliers - variável temp
# Calcular os quartis
Q1 = df['temp'].quantile(0.25)
Q3 = df['temp'].quantile(0.75)

# Calcular o intervalo interquartil (IQR)
```

```
IQR = Q3 - Q1

# Definir limites para identificar outliers
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers_inferiores = df[df['temp'] < limite_inferior]
outliers_superiores = df[df['temp'] > limite_superior]

# Contar a quantidade de outliers inferiores e superiores
quantidade_outliers_inferiores = len(outliers_inferiores)
quantidade_outliers_superiores = len(outliers_superiores)

print("Quantidade de outliers inferiores:", quantidade_outliers_inferiores)
print("Quantidade de outliers superiores:", quantidade_outliers_superiores)
```

Quantidade de outliers inferiores: 10
Quantidade de outliers superiores: 0

In [72]: *# Decisão: Manter o outlier*

```
In [73]: #outliers - variável rain_1h
# Calcular os quartis
Q1 = df['rain_1h'].quantile(0.25)
Q3 = df['rain_1h'].quantile(0.75)

# Calcular o intervalo interquartil (IQR)
IQR = Q3 - Q1

# Definir limites para identificar outliers
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers_inferiores = df[df['rain_1h'] < limite_inferior]
outliers_superiores = df[df['rain_1h'] > limite_superior]

# Contar a quantidade de outliers inferiores e superiores
quantidade_outliers_inferiores = len(outliers_inferiores)
quantidade_outliers_superiores = len(outliers_superiores)

print("Quantidade de outliers inferiores:", quantidade_outliers_inferiores)
print("Quantidade de outliers superiores:", quantidade_outliers_superiores)
```

Quantidade de outliers inferiores: 0
Quantidade de outliers superiores: 3467

In [74]: *# Decisão: Manter o outlier*

```
In [75]: #outliers - variável snow_1h
# Calcular os quartis
Q1 = df['snow_1h'].quantile(0.25)
Q3 = df['snow_1h'].quantile(0.75)

# Calcular o intervalo interquartil (IQR)
IQR = Q3 - Q1

# Definir limites para identificar outliers
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers_inferiores = df[df['snow_1h'] < limite_inferior]
```

```
outliers_superiores = df[df['snow_1h'] > limite_superior]

# Contar a quantidade de outliers inferiores e superiores
quantidade_outliers_inferiores = len(outliers_inferiores)
quantidade_outliers_superiores = len(outliers_superiores)

print("Quantidade de outliers inferiores:", quantidade_outliers_inferiores)
print("Quantidade de outliers superiores:", quantidade_outliers_superiores)
```

Quantidade de outliers inferiores: 0
Quantidade de outliers superiores: 63

In [76]: *# Decisão: Manter o outlier*

```
In [77]: #outliers - variável clouds_all
# Calcular os quartis
Q1 = df['clouds_all'].quantile(0.25)
Q3 = df['clouds_all'].quantile(0.75)

# Calcular o intervalo interquartil (IQR)
IQR = Q3 - Q1

# Definir limites para identificar outliers
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers_inferiores = df[df['clouds_all'] < limite_inferior]
outliers_superiores = df[df['clouds_all'] > limite_superior]

# Contar a quantidade de outliers inferiores e superiores
quantidade_outliers_inferiores = len(outliers_inferiores)
quantidade_outliers_superiores = len(outliers_superiores)

print("Quantidade de outliers inferiores:", quantidade_outliers_inferiores)
print("Quantidade de outliers superiores:", quantidade_outliers_superiores)
```

Quantidade de outliers inferiores: 0
Quantidade de outliers superiores: 0

In [78]: *# Decisão: Manter. Não tem outliers.*

```
In [79]: #outliers - variável traffic_volume
# Calcular os quartis
Q1 = df['traffic_volume'].quantile(0.25)
Q3 = df['traffic_volume'].quantile(0.75)

# Calcular o intervalo interquartil (IQR)
IQR = Q3 - Q1

# Definir limites para identificar outliers
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Identificar outliers
outliers_inferiores = df[df['traffic_volume'] < limite_inferior]
outliers_superiores = df[df['traffic_volume'] > limite_superior]

# Contar a quantidade de outliers inferiores e superiores
quantidade_outliers_inferiores = len(outliers_inferiores)
quantidade_outliers_superiores = len(outliers_superiores)
```

```
print("Quantidade de outliers inferiores:", quantidade_outliers_inferiores)
print("Quantidade de outliers superiores:", quantidade_outliers_superiores)
```

Quantidade de outliers inferiores: 0
Quantidade de outliers superiores: 0

```
In [80]: # Decisão: Manter. Não tem outliers.
```

Tratamento de variaveis categóricas

```
In [81]: df.sample(5)
```

Out[81]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	weather_description	data	c
	6420	None	276.70	0.0	0.0	90	Clouds	overcast clouds	2013-06-05
	15297	None	264.63	0.0	0.0	64	Clouds	broken clouds	2014-09-01
	4556	None	277.34	0.0	0.0	90	Rain	moderate rain	2013-03-31
	42029	None	299.48	0.0	0.0	90	Clouds	overcast clouds	2018-03-08
	15421	None	293.63	0.0	0.0	90	Clouds	overcast clouds	2014-09-06



```
In [82]: df['holiday'].value_counts()
```

Out[82]:

None	48126
Labor Day	7
Thanksgiving Day	6
Christmas Day	6
New Years Day	6
Martin Luther King Jr Day	6
Columbus Day	5
Veterans Day	5
Washingtons Birthday	5
Independence Day	5
Memorial Day	5
State Fair	5

Name: holiday, dtype: int64

```
In [83]: df['weather_main'].value_counts()
```

Out[83]:

Clouds	15158
Clear	13384
Mist	5949
Rain	5672
Snow	2875
Drizzle	1820
Haze	1360
Thunderstorm	1033
Fog	912
Smoke	20
Squall	4

Name: weather_main, dtype: int64

```
In [84]: df['weather_description'].value_counts()
```

Out[84]:

sky is clear11659

mist5949

overcast clouds5079

broken clouds4663

scattered clouds3460

light rain3372

few clouds1956

light snow1945

Sky is Clear1725

moderate rain1664

haze1360

light intensity drizzle1099

fog912

proximity thunderstorm673

drizzle651

heavy snow616

heavy intensity rain467

snow293

proximity shower rain136

thunderstorm124

heavy intensity drizzle64

thunderstorm with heavy rain63

thunderstorm with light rain54

proximity thunderstorm with rain52

thunderstorm with rain37

smoke20

very heavy rain18

thunderstorm with light drizzle15

proximity thunderstorm with drizzle13

light intensity shower rain13

light shower snow11

light rain and snow6

shower drizzle6

SQUALLS4

sleet3

freezing rain2

thunderstorm with drizzle2

shower snow1

Name: weather_description, dtype: int64

In [85]:

#decisão - excluir a variável 'weather_description'

#exclui a coluna 'hora_completa'

df = df.drop(columns=['weather_description'])

In [86]:

df.sample(5)

Out[86]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data	dia	mes	ano	apen
9208	None	289.30	0.00	0.0	92	Mist	2013-10-06	6	10	2013	
44444	None	286.08	2.79	0.0	1	Rain	2018-06-09	9	6	2018	
46064	None	299.95	0.00	0.0	75	Clouds	2018-08-14	14	8	2018	
8593	None	302.57	0.00	0.0	0	Clear	2013-09-07	7	9	2013	
10536	None	301.21	0.00	0.0	8	Clear	2013-12-07	7	12	2013	


```
In [87]: print(df.dtypes)
```

```
holiday                object
temp                  float64
rain_1h               float64
snow_1h              float64
clouds_all            int64
weather_main          object
data                 datetime64[ns]
dia                   int64
mes                   int64
ano                   int64
apenas_hora           int32
traffic_volume        int64
mes_ano               datetime64[ns]
dtype: object
```

```
In [88]: qtde_holiday = df['holiday'].nunique()
qtde_holiday
```

Out[88]: 12

```
In [89]: # Obter categorias únicas da coluna 'holiday'
cat_holiday = df['holiday'].unique()

# Criar um dicionário para mapear categorias para valores ordinais
mapeamento = {categoria : i+1 for i, categoria in enumerate(cat_holiday)}

# Aplicar o mapeamento à coluna 'holiday'
df['holiday'] = df['holiday'].map(mapeamento)

print(df)
```

```
      holiday  temp  rain_1h  snow_1h  clouds_all  weather_main  data \
0           1  271.73     0.0     0.0           1         Clear  2012-01-11
1           1  270.91     0.0     0.0           1         Clear  2012-01-11
2           1  270.15     0.0     0.0           1         Clear  2012-01-11
3           1  269.68     0.0     0.0           1         Clear  2012-01-11
4           1  269.44     0.0     0.0           1         Clear  2012-01-11
...         ...    ...     ...     ...         ...         ...    ...
48199        1  300.14     0.0     0.0          20        Clouds  2018-12-09
48200        1  297.82     0.0     0.0           5         Clear  2018-12-09
48201        1  296.10     0.0     0.0           5         Clear  2018-12-09
48202        1  295.32     0.0     0.0           5         Clear  2018-12-09
48203        1  294.46     0.0     0.0           1         Clear  2018-12-09

      dia  mes  ano  apenas_hora  traffic_volume  mes_ano
0      11   1  2012             0           716  2012-01-01
1      11   1  2012             1           453  2012-01-01
2      11   1  2012             2           324  2012-01-01
3      11   1  2012             3           390  2012-01-01
4      11   1  2012             4           775  2012-01-01
...     ...  ...  ...         ...         ...     ...
48199    9  12  2018            19          3510  2018-12-01
48200    9  12  2018            20          3064  2018-12-01
48201    9  12  2018            21          2705  2018-12-01
48202    9  12  2018            22          1813  2018-12-01
48203    9  12  2018            23          2842  2018-12-01
```

[48187 rows x 13 columns]

```
In [90]: qtde_weather_main = df['weather_main'].nunique()
qtde_weather_main
```

Out[90]: 11

```
In [91]: # Obter categorias únicas da coluna 'holiday'
cat_weather_main = df['weather_main'].unique()

# Criar um dicionário para mapear categorias para valores ordinais
mapeamento = {categoria : i+1 for i, categoria in enumerate(cat_weather_main)}

# Aplicar o mapeamento à coluna 'holiday'
df['weather_main'] = df['weather_main'].map(mapeamento)

print(df)
```

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data \
0	1	271.73	0.0	0.0	1	1	2012-01-11
1	1	270.91	0.0	0.0	1	1	2012-01-11
2	1	270.15	0.0	0.0	1	1	2012-01-11
3	1	269.68	0.0	0.0	1	1	2012-01-11
4	1	269.44	0.0	0.0	1	1	2012-01-11
...
48199	1	300.14	0.0	0.0	20	2	2018-12-09
48200	1	297.82	0.0	0.0	5	1	2018-12-09
48201	1	296.10	0.0	0.0	5	1	2018-12-09
48202	1	295.32	0.0	0.0	5	1	2018-12-09
48203	1	294.46	0.0	0.0	1	1	2018-12-09

	dia	mes	ano	apenas_hora	traffic_volume	mes_ano
0	11	1	2012	0	716	2012-01-01
1	11	1	2012	1	453	2012-01-01
2	11	1	2012	2	324	2012-01-01
3	11	1	2012	3	390	2012-01-01
4	11	1	2012	4	775	2012-01-01
...
48199	9	12	2018	19	3510	2018-12-01
48200	9	12	2018	20	3064	2018-12-01
48201	9	12	2018	21	2705	2018-12-01
48202	9	12	2018	22	1813	2018-12-01
48203	9	12	2018	23	2842	2018-12-01

[48187 rows x 13 columns]

```
In [92]: #cria variáveis dummy para 'holiday' e 'weather_main'
#df = pd.get_dummies(df, columns=['holiday', 'weather_main'])
```

```
In [93]: df.head(5)
```

Out[93]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data	dia	mes	ano	apenas_hc
0	1	271.73	0.0	0.0	1	1	2012-01-11	11	1	2012	
1	1	270.91	0.0	0.0	1	1	2012-01-11	11	1	2012	
2	1	270.15	0.0	0.0	1	1	2012-01-11	11	1	2012	
3	1	269.68	0.0	0.0	1	1	2012-01-11	11	1	2012	
4	1	269.44	0.0	0.0	1	1	2012-01-11	11	1	2012	

```
In [94]: # Armazenar a coluna que queremos mover
coluna_a_mover = df.pop('traffic_volume')

# Anexar a coluna de volta ao final do DataFrame
df['traffic_volume'] = coluna_a_mover
```

```
In [95]: df.head(5)
```

Out[95]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data	dia	mes	ano	apenas_hc
0	1	271.73	0.0	0.0	1	1	2012-01-11	11	1	2012	
1	1	270.91	0.0	0.0	1	1	2012-01-11	11	1	2012	
2	1	270.15	0.0	0.0	1	1	2012-01-11	11	1	2012	
3	1	269.68	0.0	0.0	1	1	2012-01-11	11	1	2012	
4	1	269.44	0.0	0.0	1	1	2012-01-11	11	1	2012	

```
In [96]: df.columns
```

Out[96]:

Index(['holiday', 'temp', 'rain_1h', 'snow_1h', 'clouds_all', 'weather_main', 'data', 'dia', 'mes', 'ano', 'apenas_hora', 'mes_ano', 'traffic_volume'], dtype='object')

```
In [97]: df.shape
```

Out[97]:

(48187, 13)

```
In [98]: df.dtypes
```

Out[98]:

holiday int64
temp float64
rain_1h float64
snow_1h float64
clouds_all int64
weather_main int64
data datetime64[ns]
dia int64
mes int64
ano int64
apenas_hora int32
mes_ano datetime64[ns]
traffic_volume int64
dtype: object

```
In [99]: df.sample(5)
```

Out[99]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data	dia	mes	ano	apen.
22837	1	289.23	0.0	0.0	40	9	2016-04-24	24	4	2016	
12052	1	267.90	0.0	0.0	90	2	2014-02-17	17	2	2014	
33841	1	284.84	0.0	0.0	90	2	2017-05-18	18	5	2017	
17491	1	302.58	0.0	0.0	40	2	2015-07-26	26	7	2015	
45456	1	291.35	0.0	0.0	90	6	2018-07-20	20	7	2018	

8 - Construção, Treinamento e Avaliação do Modelo 1 com Regressão Logística (Benchmark)

```
In [100... # Preparando os dados de treino e teste
X = df.drop(columns=['traffic_volume', 'data', 'mes_ano'])
y = df['traffic_volume']

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, random
```

```
In [101... X_treino.dtypes
```

```
Out[101]: holiday          int64
temp          float64
rain_1h       float64
snow_1h       float64
clouds_all    int64
weather_main  int64
dia           int64
mes           int64
ano           int64
apenas_hora   int32
dtype: object
```

Padronização

```
In [102... scaler = StandardScaler()
```

```
In [103... scaler.fit(X_treino)
```

```
Out[103]: ▾ StandardScaler
StandardScaler()
```

```
In [104... X_treino = scaler.transform(X_treino)
```

```
In [105... X_teste = scaler.transform(X_teste)
```

```
In [106... X_treino[:5]

Out[106]: array([[ -0.03148663, -0.29427646, -0.00776763, -0.02489695, -1.26456512,
        -0.96219611, -0.30850414,  1.01831146,  0.2572608 , -0.05734534],
       [ -0.03148663, -0.45209304, -0.00776763, -0.02489695,  1.04227068,
         0.73806851, -1.67928199,  1.01831146,  1.31261321,  1.67092796],
       [ -0.03148663,  0.61119429, -0.00776763, -0.02489695,  1.04227068,
         0.73806851,  1.1765052 ,  0.4322164 ,  0.78493701, -1.20952754],
       [ -0.03148663, -0.37735742, -0.00776763, -0.02489695,  0.17079938,
        -0.53712995,  0.49111628,  1.01831146,  0.2572608 ,  1.23885963],
       [ -0.03148663,  1.23038965, -0.00776763, -0.02489695, -1.23893361,
        -0.96219611,  1.29073669,  0.13916888, -0.27041541, -0.34539089]])

In [107... X_teste[:5]

Out[107]: array([[ -0.03148663,  0.20435836, -0.00277587, -0.02489695,  1.04227068,
         0.73806851,  0.60534777,  0.72526393,  1.31261321, -0.34539089],
       [ -0.03148663,  1.14917148, -0.00776763, -0.02489695,  0.78595559,
         1.16313467,  0.2626533 , -0.15387865, -0.79809161,  1.52690518],
       [ -0.03148663,  1.45765148, -0.00776763, -0.02489695, -1.23893361,
        -0.96219611,  0.03419033,  0.72526393,  1.31261321,  1.23885963],
       [ -0.03148663, -0.59515622, -0.00776763, -0.02489695, -1.23893361,
        -0.96219611,  0.83381074, -1.03302123, -1.32576782,  1.09483686],
       [ -0.03148663, -1.08022984, -0.00776763, -0.02489695, -1.23893361,
        -0.96219611,  0.2626533 , -1.32606875,  1.31261321, -0.77745922]])
```

8.1 - Modelo de Regressão Linear Múltipla

```
In [108... # Cria o modelo
modelo_v1 = LinearRegression()
# Treinamento
modelo_v1.fit(X_treino, y_treino)
# Avaliação do modelo
y_pred = modelo_v1.predict(X_teste)

In [109... # Calcula as métricas de avaliação do modelo
evs_1 = explained_variance_score(y_teste, y_pred)
mae_1 = mean_absolute_error(y_teste, y_pred)
mse_1 = mean_squared_error(y_teste, y_pred)
rmse_1 = np.sqrt(mse_1)
r2_1 = r2_score(y_teste, y_pred)

print("Resultados do modelo de Regressão linear múltipla")
print("Explained Variance Score:", evs_1)
print("Mean Absolute Error:", mae_1)
print("Mean Squared Error:", mse_1)
print("Root Mean Squared Error:", rmse_1)
print("R² Score:", r2_1)
```

```
Resultados do modelo de Regressão linear múltipla
Explained Variance Score: 0.13053905958517564
Mean Absolute Error: 1637.4750590437454
Mean Squared Error: 3435784.5965426057
Root Mean Squared Error: 1853.5869541358468
R² Score: 0.13048000277479554
```

8.2 - Modelo de Random Forest

```
In [110... # Cria o modelo
modelo_v2 = RandomForestRegressor(max_depth=3)
# Treinamento
```

```

modelo_v2.fit(X_treino, y_treino)
# Avaliação do modelo
y_pred = modelo_v2.predict(X_teste)

```

```

In [111... # Calcula as métricas de avaliação do modelo
evs_2 = explained_variance_score(y_teste, y_pred)
mae_2 = mean_absolute_error(y_teste, y_pred)
mse_2 = mean_squared_error(y_teste, y_pred)
rmse_2 = np.sqrt(mse_2)
r2_2 = r2_score(y_teste, y_pred)

print("Resultados do modelo Random Forest")
print("Explained Variance Score:", evs_1)
print("Mean Absolute Error:", mae_1)
print("Mean Squared Error:", mse_1)
print("Root Mean Squared Error:", rmse_1)
print("R² Score:", r2_1)

```

```

Resultados do modelo Random Forest
Explained Variance Score: 0.13053905958517564
Mean Absolute Error: 1637.4750590437454
Mean Squared Error: 3435784.5965426057
Root Mean Squared Error: 1853.5869541358468
R² Score: 0.13048000277479554

```

8.3 - Modelo de Rede Neural

```

In [112... # Criar o modelo
modelo_v3 = MLPRegressor(hidden_layer_sizes=(100, 50), max_iter=500, activation='re
# Treinamento
modelo_v3.fit(X_treino, y_treino)
# Avaliação do modelo
y_pred = modelo_v3.predict(X_teste)

```

```

C:\Users\Chilov\anaconda3\lib\site-packages\sklearn\neural_network\_multilayer_per
ceptron.py:684: ConvergenceWarning: Stochastic Optimizer: Maximum iterations (500)
reached and the optimization hasn't converged yet.
warnings.warn(

```

```

In [113... # Calcula as métricas de avaliação do modelo
evs_3 = explained_variance_score(y_teste, y_pred)
mae_3 = mean_absolute_error(y_teste, y_pred)
mse_3 = mean_squared_error(y_teste, y_pred)
rmse_3 = np.sqrt(mse_3)
r2_3 = r2_score(y_teste, y_pred)

print("Resultados do modelo de Redes Neurais")
print("Explained Variance Score:", evs_3)
print("Mean Absolute Error:", mae_3)
print("Mean Squared Error:", mse_3)
print("Root Mean Squared Error:", rmse_3)
print("R² Score:", r2_3)

```

```

Resultados do modelo de Redes Neurais
Explained Variance Score: 0.7819596830526052
Mean Absolute Error: 630.9557407644278
Mean Squared Error: 861905.22660345
Root Mean Squared Error: 928.3885105942717
R² Score: 0.7818711245755108

```

8.4 - Modelo de XGBOOST

```
In [114... # Criar o modelo
modelo_v4 = XGBRegressor(learning_rate=0.01, n_estimators=1000, max_depth=3, random_state=42)
# Treinamento
modelo_v4.fit(X_treino, y_treino)
# Avaliação do modelo
y_pred = modelo_v4.predict(X_teste)
```

```
In [115... # Calcula as métricas de avaliação do modelo
evs_4 = explained_variance_score(y_teste, y_pred)
mae_4 = mean_absolute_error(y_teste, y_pred)
mse_4 = mean_squared_error(y_teste, y_pred)
rmse_4 = np.sqrt(mse_4)
r2_4 = r2_score(y_teste, y_pred)

print("Resultados do modelo XGB00ST")
print("Explained Variance Score:", evs_4)
print("Mean Absolute Error:", mae_4)
print("Mean Squared Error:", mse_4)
print("Root Mean Squared Error:", rmse_4)
print("R² Score:", r2_4)
```

Resultados do modelo XGB00ST
Explained Variance Score: 0.7838492783032498
Mean Absolute Error: 633.4688980889335
Mean Squared Error: 854090.2138668308
Root Mean Squared Error: 924.1700135077045
R² Score: 0.7838489289640334

8.5 - Modelo de LIGHTGBM

```
In [116... # Criar o modelo
modelo_v5 = LGBMRegressor(learning_rate=0.01, n_estimators=1000, max_depth=3, random_state=42)
# Treinamento
modelo_v5.fit(X_treino, y_treino)
# Avaliação do modelo
y_pred = modelo_v5.predict(X_teste)
```

C:\Users\Chilov\anaconda3\lib\site-packages\joblib\externals\loky\backend\context.py:110: UserWarning: Could not find the number of physical cores for the following reason:
found 0 physical cores < 1
Returning the number of logical cores instead. You can silence this warning by setting LOKY_MAX_CPU_COUNT to the number of cores you want to use.
warnings.warn(
File "C:\Users\Chilov\anaconda3\lib\site-packages\joblib\externals\loky\backend\context.py", line 217, in _count_physical_cores
raise ValueError(
ValueError: Could not find the number of physical cores for the following reason:
found 0 physical cores < 1
Returning the number of logical cores instead. You can silence this warning by setting LOKY_MAX_CPU_COUNT to the number of cores you want to use.

In [117...

localhost:8888/nbconvert/html/Projeto prev trafego.ipynb?download=false

Resultados do modelo lightGBM
Explained Variance Score: 0.7836758384799476
Mean Absolute Error: 634.1314146440678
Mean Squared Error: 854775.1417106433
Root Mean Squared Error: 924.5405030125199
R² Score: 0.7836755890935855

8.6 - Modelo de Séries Temporais - ARIMA

```
In [118... df.sample(5)
```

Out[118]:

	holiday	temp	rain_1h	snow_1h	clouds_all	weather_main	data	dia	mes	ano	apen
45639	1	290.15	0.0	0.0	90	2	2018-07-26	26	7	2018	
21481	1	272.76	0.0	0.0	1	1	2016-02-24	24	2	2016	
14188	1	300.94	0.0	0.0	75	2	2014-05-31	31	5	2014	
41876	1	271.61	0.0	0.0	90	8	2018-03-04	4	3	2018	
7687	1	283.69	0.0	0.0	0	1	2013-07-29	29	7	2013	

```
In [119... df.columns
```

Out[119]: Index(['holiday', 'temp', 'rain_1h', 'snow_1h', 'clouds_all', 'weather_main', 'data', 'dia', 'mes', 'ano', 'apenas_hora', 'mes_ano', 'traffic_volume'], dtype='object')

```
In [120... # Preparando os dados de treino e teste
df_serie_temp = df[['data', 'traffic_volume']]
```

```
In [121... df_serie_temp
```

Out[121]:

	data	traffic_volume
0	2012-01-11	716
1	2012-01-11	453
2	2012-01-11	324
3	2012-01-11	390
4	2012-01-11	775
...
48199	2018-12-09	3510
48200	2018-12-09	3064
48201	2018-12-09	2705
48202	2018-12-09	1813
48203	2018-12-09	2842

48187 rows × 2 columns

In [122...

```
#definindo 'data' como índice
df_serie_temp.set_index('data', inplace=True)
```

In [123...

```
df_serie_temp
```

Out[123]:

	traffic_volume
data	
2012-01-11	716
2012-01-11	453
2012-01-11	324
2012-01-11	390
2012-01-11	775
...	...
2018-12-09	3510
2018-12-09	3064
2018-12-09	2705
2018-12-09	1813
2018-12-09	2842

48187 rows × 1 columns

In [124...

```
df_serie_temp.dtypes
```

Out[124]:

```
traffic_volume    int64
dtype: object
```

In [125...

```
soma = df_serie_temp['traffic_volume'].sum()
is_numeric = np.isfinite(soma)
```


In [126... `is_numeric`

Out[126]: `True`

In [127... `#coluna traffic_volume tem valores válidos`

```
In [128... # Visualizando a série temporal
df_serie_temp.index = pd.to_datetime(df_serie_temp.index)

plt.figure(figsize=(10, 6))
plt.plot(df_serie_temp)
plt.title('Série Temporal')
plt.xlabel('Data')
plt.ylabel('Valor')
plt.show()
```



```
In [129... #verificando se a série temporal é estacionária com base no Teste Dickey-Fuller Aum
resultado_adf = adfuller(df_serie_temp)

# Imprimindo os resultados
print('Estatística ADF:', resultado_adf[0])
print('Valor-p:', resultado_adf[1])
print('Valores críticos:')
for chave, valor in resultado_adf[4].items():
    print(f'    {chave}: {valor}')
```

```
Estatística ADF: -28.09090129989716
Valor-p: 0.0
Valores críticos:
    1%: -3.430485863397371
    5%: -2.8616000487800735
    10%: -2.566801961988572
```

```
In [130... #Se a estatística ADF for menor que os valores críticos para um nível de significân
#(por exemplo, 0.01, 0.05 ou 0.10), você pode rejeitar a hipótese nula de não estac
#e concluir que a série temporal é estacionária
#Neste caso, como a estatística ADF (-28) é muito menor do que o valor crítico (-3)
#pode-se concluir com confiança que a série temporal é estacionária.
```

```
In [131... # Dividindo os dados em conjuntos de treinamento e teste (por exemplo, 80% para tre
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, random
#convertendo para tipo array para o treinamento
X_treino_array = X_treino.values.ravel() # Convertendo para um array unidimensiona
y_teste_array = y_teste.values.ravel() # Convertendo para um array unidimensiona
X_teste_array = X_teste.values.ravel() # Convertendo para um array unidimensional
y_teste_array = y_teste.values.ravel() # Convertendo para um array unidimensional
```

```
In [132... # Criar o modelo
modelo_v6 = ARIMA(X_treino_array, order=(5,1,0))
```

```
In [133... modelo_v6
```

```
Out[133]: <statsmodels.tsa.arima.model.ARIMA at 0x211ace00d30>
```

```
In [134... # Ajustar o modelo ARIMA aos dados de treinamento
#modelo_arima = ARIMA(X_treino, order=(5,1,0))
modelo_arima_ajustado_v6 = modelo_v6.fit()

# Fazer previsões nos dados de teste
y_pred = modelo_arima_ajustado_v6.forecast(steps=len(X_teste))

# Calculando o RMSE
rmse_6 = np.sqrt(mean_squared_error(y_teste, y_pred))
print("RMSE:", rmse_6)
```

RMSE: 3358.144056774965

8.7 - Modelo de Séries Temporais - LSTM

```
In [135... # Função para preparar os dados para a LSTM
def preparar_dados_para_lstm(serie_temporal, passos_de_tempo):
    X, y = [], []
    for i in range(len(serie_temporal) - passos_de_tempo):
        X.append(serie_temporal[i:(i + passos_de_tempo)])
        y.append(serie_temporal[i + passos_de_tempo])
    return np.array(X), np.array(y)
```

```
In [136... # Definir o número de passos de tempo
passos_de_tempo = 10
# Preparar os dados para a LSTM
X, y = preparar_dados_para_lstm(df_serie_temp['traffic_volume'], passos_de_tempo)

# Redimensionar os dados para o formato [amostras, passos de tempo, características]
X = np.reshape(X, (X.shape[0], X.shape[1], 1))

# Dividir os dados em conjuntos de treinamento e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=False)

# Criar o modelo LSTM
modelo_v7 = Sequential()
modelo_v7.add(LSTM(50, input_shape=(passos_de_tempo, 1)))
modelo_v7.add(Dense(1))
modelo_v7.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v7.fit(X_treino, y_treino, epochs=10, batch_size=32)

# Fazer previsões
y_pred = modelo_v7.predict(X_teste)
```

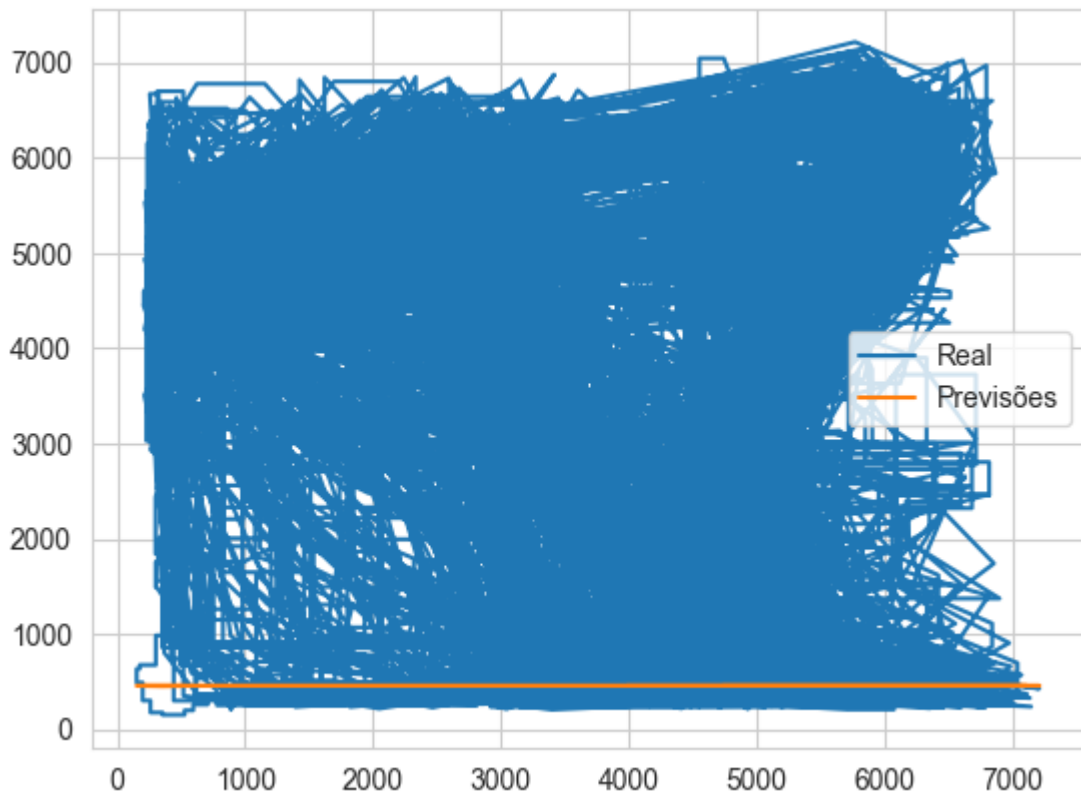
```
# Imprimir algumas previsões
print(y_pred[:10])
```

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\rnn\rnn.py:204: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(**kwargs)
Epoch 1/10
1205/1205 ————— 8s 5ms/step - loss: 14515213.0000
Epoch 2/10
1205/1205 ————— 6s 5ms/step - loss: 14101632.0000
Epoch 3/10
1205/1205 ————— 7s 5ms/step - loss: 13890107.0000
Epoch 4/10
1205/1205 ————— 6s 5ms/step - loss: 13694529.0000
Epoch 5/10
1205/1205 ————— 6s 5ms/step - loss: 13365287.0000
Epoch 6/10
1205/1205 ————— 6s 5ms/step - loss: 13199586.0000
Epoch 7/10
1205/1205 ————— 6s 5ms/step - loss: 12827582.0000
Epoch 8/10
1205/1205 ————— 6s 5ms/step - loss: 12635863.0000
Epoch 9/10
1205/1205 ————— 7s 6ms/step - loss: 12286808.0000
Epoch 10/10
1205/1205 ————— 7s 6ms/step - loss: 12160044.0000
302/302 ————— 1s 4ms/step
[[456.5219 ]
 [456.5219 ]
 [456.5219 ]
 [456.5219 ]
 [456.5219 ]
 [456.5219 ]
 [456.51172]
 [456.43472]
 [456.52167]
 [456.5219 ]]
```

In [137...

```
# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()
```



In [138... *#o algoritmo LSTM não capturou padrão nos dados*

```
In [139... # Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_7 = mean_absolute_error(y_teste, y_pred)
print("MAE:", mae_7)
# Calcular o RMSE
rmse_7 = np.sqrt(mean_squared_error(y_teste, y_pred))
print("RMSE:", rmse_7)
```

MAE: 2822.707280993115
RMSE: 3422.1508876148723

8.8 - Modelo de Séries Temporais - FNN

```
In [140... # Normalização dos dados
scaler = MinMaxScaler()
scaled_data = scaler.fit_transform(df['traffic_volume'].values.reshape(-1, 1))

# Divisão em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(scaled_data, seq_length)

# Divisão em conjuntos de treinamento e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=False)

# Reformatação dos dados (se necessário)
X_treino = X_treino.reshape(-1, seq_length, 1)
X_teste = X_teste.reshape(-1, seq_length, 1)
# Construir o modelo FNN
```

```

#observar que o primeiro número do input_shape deve ser o mesmo do seq_length
modelo_v8 = Sequential([
    Dense(64, activation='relu', input_shape=(10,1)),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v8.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v8.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v8.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v8.predict(X_teste)

# Visualizar os resultados
# Selecionar o último ponto de cada sequência para plotar no eixo x
x_plot = X_teste[:, -1, 0]

# Selecionar apenas os primeiros valores de y_teste e y_pred para plotar
y_plot = y_teste[:, 0]
y_pred_plot = y_pred[:, 0]

# Plotar os valores reais
plt.plot(x_plot, y_plot, label='Real')
# Plotar as previsões
plt.plot(x_plot, y_pred_plot, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\core\dense.py:87: Use rWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

1205/1205 ————— 5s 3ms/step - loss: 0.0779

Epoch 2/10

1205/1205 ————— 3s 3ms/step - loss: 0.0691

Epoch 3/10

1205/1205 ————— 3s 2ms/step - loss: 0.0690

Epoch 4/10

1205/1205 ————— 3s 2ms/step - loss: 0.0683

Epoch 5/10

1205/1205 ————— 3s 3ms/step - loss: 0.0682

Epoch 6/10

1205/1205 ————— 4s 3ms/step - loss: 0.0680

Epoch 7/10

1205/1205 ————— 4s 3ms/step - loss: 0.0671

Epoch 8/10

1205/1205 ————— 3s 2ms/step - loss: 0.0675

Epoch 9/10

1205/1205 ————— 3s 3ms/step - loss: 0.0671

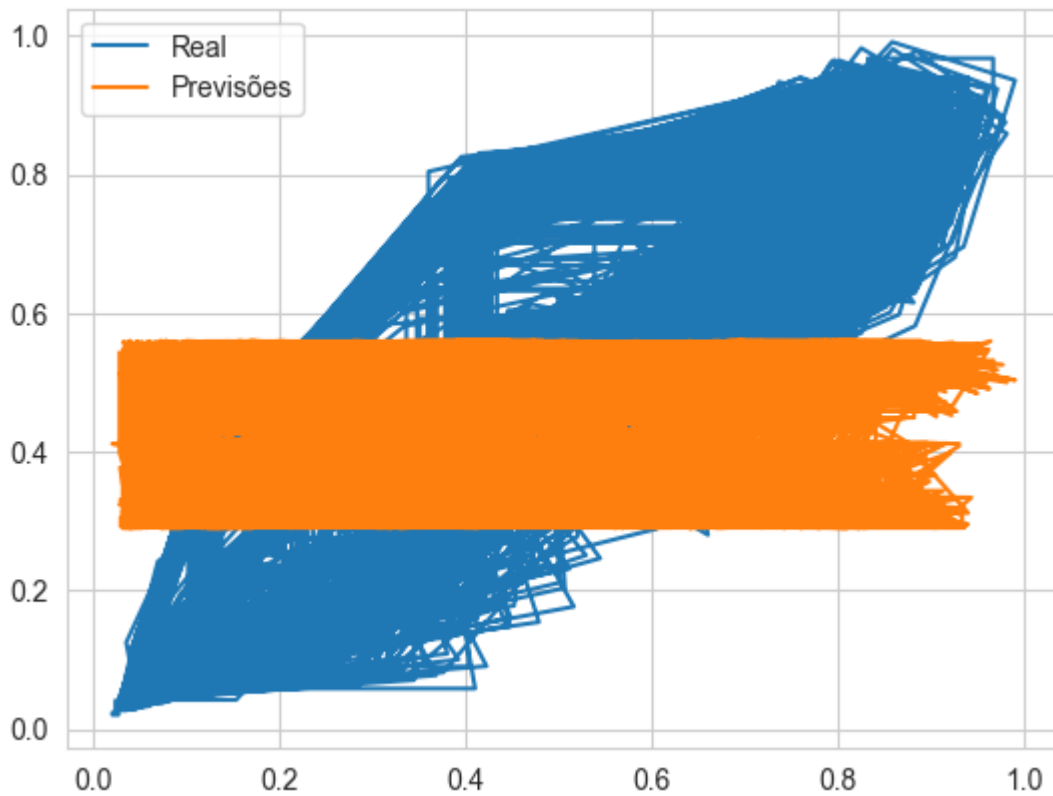
Epoch 10/10

1205/1205 ————— 3s 2ms/step - loss: 0.0676

302/302 ————— 1s 1ms/step - loss: 0.0631

Loss: 0.0638209655880928

302/302 ————— 0s 1ms/step



```
In [141... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_reformulado
y_pred_reformulado = y_pred[:, -1, :] # Selecionar apenas a última previsão de cada linha

# Supondo que `y` são os valores reais e `y_pred` são as previsões do modelo
mae_8 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_8)
# Calcular o RMSE
rmse_8 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_8)

MAE: 0.2529087409714181
RMSE: 0.29226953115230214
```

```
In [142... #o algoritmo FNN não capturou padrão nos dados
```

8.9 - Modelo de Séries Temporais - 1D CNN

```
In [143... # Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)

# Divisão dos dados em conjuntos de treinamento e teste
```

```

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo 1D CNN
modelo_v9 = Sequential([
    Conv1D(filters=64, kernel_size=3, activation='relu', input_shape=(seq_length, 1)),
    MaxPooling1D(pool_size=2),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v9.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v9.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v9.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v9.predict(X_teste)

# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

1205/1205 ————— 5s 3ms/step - loss: 0.0263

Epoch 2/10

1205/1205 ————— 3s 3ms/step - loss: 0.0073

Epoch 3/10

1205/1205 ————— 3s 3ms/step - loss: 0.0066

Epoch 4/10

1205/1205 ————— 3s 3ms/step - loss: 0.0063

Epoch 5/10

1205/1205 ————— 3s 3ms/step - loss: 0.0060

Epoch 6/10

1205/1205 ————— 4s 3ms/step - loss: 0.0063

Epoch 7/10

1205/1205 ————— 4s 3ms/step - loss: 0.0061

Epoch 8/10

1205/1205 ————— 3s 3ms/step - loss: 0.0059

Epoch 9/10

1205/1205 ————— 4s 3ms/step - loss: 0.0059


Epoch 10/10

1205/1205 ————— 4s 3ms/step - loss: 0.0057

302/302 ————— 1s 2ms/step - loss: 0.0034

Loss: 0.003359844908118248

302/302 ————— 1s 3ms/step



```
In [144... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_true_reformulado
y_pred_reformulado = y_pred.squeeze() # Remove a dimensão extra de y_pred

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_9 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_9)
# Calcular o RMSE
rmse_9 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_9)

MAE: 0.3154027552191197
RMSE: 0.3853059938242588
```

```
In [145... # bom modelo
```

8.10 - Modelo de Séries Temporais - TANN

```
In [146... # Supondo que 'df' é o seu DataFrame com a série temporal, onde 'traffic_volume' é
# Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)
```

```

# Divisão dos dados em conjuntos de treinamento e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo TANN
modelo_v10 = Sequential([
    TimeDistributed(Dense(64, activation='relu'), input_shape=(seq_length, 1)),
    Dense(1) # Camada de saída única para prever a média
])

# Compilar o modelo
modelo_v10.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v10.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v10.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v10.predict(X_teste)

# Visualizar os resultados
import matplotlib.pyplot as plt
# Selecionar a última previsão de cada instância de teste
y_pred_plot = y_pred[:, -1, 0] # Selecionar apenas a última previsão de cada instância
plt.plot(y_teste, label='Real')
# Plotar as previsões
plt.plot(y_pred_plot, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\core\wrapper.py:27: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(**kwargs)
```

1205/1205 ————— 5s 3ms/step - loss: 0.0908

Epoch 2/10

1205/1205 ————— 3s 2ms/step - loss: 0.0753

Epoch 3/10

1205/1205 ————— 3s 2ms/step - loss: 0.0746

Epoch 4/10

1205/1205 ————— 3s 2ms/step - loss: 0.0754

Epoch 5/10

1205/1205 ————— 3s 2ms/step - loss: 0.0750

Epoch 6/10

1205/1205 ————— 3s 2ms/step - loss: 0.0750

Epoch 7/10

1205/1205 ————— 3s 2ms/step - loss: 0.0750

Epoch 8/10

1205/1205 ————— 3s 3ms/step - loss: 0.0747

Epoch 9/10

1205/1205 ————— 3s 2ms/step - loss: 0.0748


Epoch 10/10

1205/1205 ————— 3s 3ms/step - loss: 0.0750

302/302 ————— 1s 3ms/step - loss: 0.0727

Loss: 0.07327903062105179

302/302 ————— 1s 3ms/step



```
In [147... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Selecionar a última previsão de cada instância de teste
y_pred_reformulado = y_pred[:, -1, 0] # Selecionar apenas a última previsão de cada instância

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_10 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_10)
# Calcular o RMSE
rmse_10 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_10)

MAE: 0.24454050666677205
RMSE: 0.2781357115256738
```

```
In [148... #o algoritmo TANN não capturou padrão nos dados
```

8.11 - Avaliação do melhor algoritmo

```
In [149... # Defina os valores para cada modelo
modelos = ['Regressão Linear Múltipla', 'Random Forest', 'Rede Neural', 'XGBoost',
evs = [evs_1, evs_2, evs_3, evs_4, evs_5, 0, 0, 0, 0, 0]
mae = [mae_1, mae_2, mae_3, mae_4, mae_5, 0, mae_7, mae_8, mae_9, mae_10]
mse = [mse_1, mse_2, mse_3, mse_4, mse_5, 0, 0, 0, 0, 0]
rmse = [rmse_1, rmse_2, rmse_3, rmse_4, rmse_5, rmse_6, rmse_7, rmse_8, rmse_9, rmse_10]
r2 = [r2_1, r2_2, r2_3, r2_4, r2_5, 0, 0, 0, 0, 0]

# Crie um DataFrame usando Pandas
df_resumo_modelos = pd.DataFrame({
    'Modelo': modelos,
    'EVS': evs,
    'MAE': mae,
    'MSE': mse,
    'RMSE': rmse,
```

```
'R2': r2,
})

# Exiba o DataFrame
df_resumo_modelos.index += 1
df_resumo_modelos_R2 = df_resumo_modelos.sort_values(by='R2', ascending=False)
print("Avaliação do modelos com base no R2\n")
print(df_resumo_modelos_R2.to_string(index=True))
#print(df_resumo_modelos.to_string(index=False))
```

Avaliação do modelos com base no R2					
	Modelo	EVS	MAE	MSE	RMSE
R2					
4	XGBoost	0.783849	633.468898	8.540902e+05	924.170014
0.783849					
5	LightGBM	0.783676	634.131415	8.547751e+05	924.540503
0.783676					
3	Rede Neural	0.781960	630.955741	8.619052e+05	928.388511
0.781871					
2	Random Forest	0.747743	704.333199	9.967572e+05	998.377261
0.747743					
1	Regressão Linear Múltipla	0.130539	1637.475059	3.435785e+06	1853.586954
0.130480					
6	ARIMA	0.000000	0.000000	0.000000e+00	3358.144057
0.000000					
7	LSTM	0.000000	2822.707281	0.000000e+00	3422.150888
0.000000					
8	FNN	0.000000	0.252909	0.000000e+00	0.292270
0.000000					
9	CNN	0.000000	0.315403	0.000000e+00	0.385306
0.000000					
10	TANN	0.000000	0.244541	0.000000e+00	0.278136
0.000000					

In [150...

```
df_resumo_modelos_evs = df_resumo_modelos.sort_values(by='EVS', ascending=False)
print("Avaliação do modelos com base no EVS\n")
print(df_resumo_modelos_evs.to_string(index=True))
```

Avaliação do modelos com base no EVS					
	Modelo	EVS	MAE	MSE	RMSE
R2					
4	XGBoost	0.783849	633.468898	8.540902e+05	924.170014
0.783849					
5	LightGBM	0.783676	634.131415	8.547751e+05	924.540503
0.783676					
3	Rede Neural	0.781960	630.955741	8.619052e+05	928.388511
0.781871					
2	Random Forest	0.747743	704.333199	9.967572e+05	998.377261
0.747743					
1	Regressão Linear Múltipla	0.130539	1637.475059	3.435785e+06	1853.586954
0.130480					
6	ARIMA	0.000000	0.000000	0.000000e+00	3358.144057
0.000000					
7	LSTM	0.000000	2822.707281	0.000000e+00	3422.150888
0.000000					
8	FNN	0.000000	0.252909	0.000000e+00	0.292270
0.000000					
9	CNN	0.000000	0.315403	0.000000e+00	0.385306
0.000000					
10	TANN	0.000000	0.244541	0.000000e+00	0.278136
0.000000					

In [151...

```
df_resumo_modelos_rmse = df_resumo_modelos.sort_values(by='RMSE', ascending=True)
print("Avaliação do modelos com base no RMSE\n")
print(df_resumo_modelos_rmse.to_string(index=True))
```

Avaliação do modelos com base no RMSE					
	Modelo	EVS	MAE	MSE	RMSE
R2					
10	TANN	0.000000	0.244541	0.000000e+00	0.278136
0.000000					
8	FNN	0.000000	0.252909	0.000000e+00	0.292270
0.000000					
9	CNN	0.000000	0.315403	0.000000e+00	0.385306
0.000000					
4	XGBoost	0.783849	633.468898	8.540902e+05	924.170014
0.783849					
5	LightGBM	0.783676	634.131415	8.547751e+05	924.540503
0.783676					
3	Rede Neural	0.781960	630.955741	8.619052e+05	928.388511
0.781871					
2	Random Forest	0.747743	704.333199	9.967572e+05	998.377261
0.747743					
1	Regressão Linear Múltipla	0.130539	1637.475059	3.435785e+06	1853.586954
0.130480					
6	ARIMA	0.000000	0.000000	0.000000e+00	3358.144057
0.000000					
7	LSTM	0.000000	2822.707281	0.000000e+00	3422.150888
0.000000					

Seleção do Modelo

O melhor modelo é o v_9. Então seguiremos com o modelo_v9 1D CNN

8.12 - Otimização do modelo

8.12.1 - Otimização somente com mudança de hiperparâmetro - alterando kernel_size

In [152...

```
# Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)

# Divisão dos dados em conjuntos de treinamento e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
```

```

X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo 1D CNN
modelo_v11 = Sequential([
    Conv1D(filters=64, kernel_size=4, activation='relu', input_shape=(seq_length, 1),
    MaxPooling1D(pool_size=2),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v11.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v11.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v11.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v11.predict(X_teste)

# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

1205/1205 ————— 5s 3ms/step - loss: 0.0371

Epoch 2/10

1205/1205 ————— 4s 3ms/step - loss: 0.0159

Epoch 3/10

1205/1205 ————— 3s 3ms/step - loss: 0.0139

Epoch 4/10

1205/1205 ————— 3s 3ms/step - loss: 0.0129

Epoch 5/10

1205/1205 ————— 3s 3ms/step - loss: 0.0123

Epoch 6/10

1205/1205 ————— 3s 3ms/step - loss: 0.0123

Epoch 7/10

1205/1205 ————— 3s 3ms/step - loss: 0.0118

Epoch 8/10

1205/1205 ————— 3s 3ms/step - loss: 0.0119

Epoch 9/10

1205/1205 ————— 3s 3ms/step - loss: 0.0114

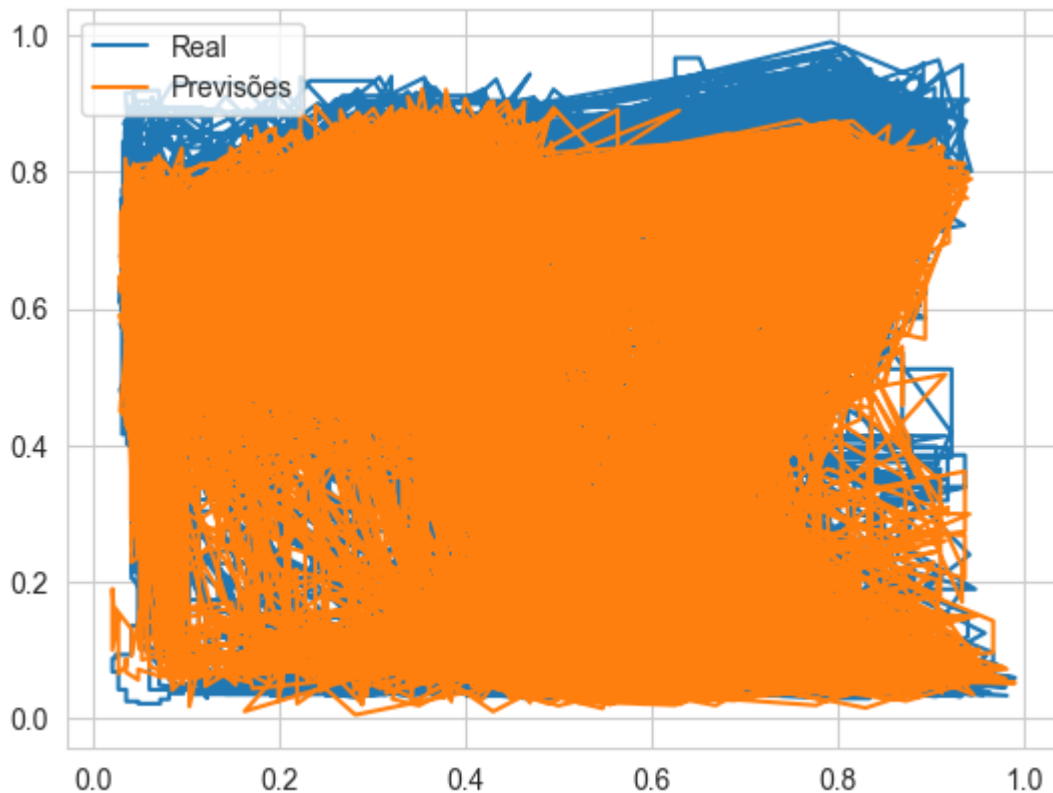
Epoch 10/10

1205/1205 ————— 4s 3ms/step - loss: 0.0113

302/302 ————— 1s 2ms/step - loss: 0.0079

Loss: 0.00763642368838191

302/302 ————— 1s 2ms/step



```
In [153... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_true_reformulado
y_pred_reformulado = y_pred.squeeze() # Remove a dimensão extra de y_pred

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_11 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_11)
# Calcular o RMSE
rmse_11 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_11)

MAE: 0.30732144461489064
RMSE: 0.37487337676039667
```

```
In [154... # após testes, verificou-se que o melhor kernel_size é 4.
```

8.12.2 - Otimização alterando o pool_size

```
In [155... # Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)

# Divisão dos dados em conjuntos de treinamento e teste
```

```

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo 1D CNN
modelo_v12 = Sequential([
    Conv1D(filters=64, kernel_size=4, activation='relu', input_shape=(seq_length, 1)),
    MaxPooling1D(pool_size=4),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v12.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v12.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v12.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v12.predict(X_teste)

# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

1205/1205 ————— 5s 3ms/step - loss: 0.0616

Epoch 2/10

1205/1205 ————— 4s 3ms/step - loss: 0.0324

Epoch 3/10

1205/1205 ————— 4s 3ms/step - loss: 0.0272

Epoch 4/10

1205/1205 ————— 4s 3ms/step - loss: 0.0258

Epoch 5/10

1205/1205 ————— 4s 3ms/step - loss: 0.0253

Epoch 6/10

1205/1205 ————— 4s 3ms/step - loss: 0.0251

Epoch 7/10

1205/1205 ————— 4s 3ms/step - loss: 0.0249

Epoch 8/10

1205/1205 ————— 4s 3ms/step - loss: 0.0238

Epoch 9/10

1205/1205 ————— 3s 3ms/step - loss: 0.0235


Epoch 10/10

1205/1205 ————— 3s 3ms/step - loss: 0.0234

302/302 ————— 1s 2ms/step - loss: 0.0162

Loss: 0.015724292024970055

302/302 ————— 1s 2ms/step



```
In [156... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_true_reformulado
y_pred_reformulado = y_pred.squeeze() # Remove a dimensão extra de y_pred

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_12 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_12)
# Calcular o RMSE
rmse_12 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_12)

MAE: 0.29687754086710577
RMSE: 0.35995624219990624
```

```
In [157... # após testes, verificou-se que o melhor pool_size é 4.
```

8.12.3 - Otimização alterando o batch_size

```
In [158... # Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)

# Divisão dos dados em conjuntos de treinamento e teste
```

```

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo 1D CNN
modelo_v13 = Sequential([
    Conv1D(filters=64, kernel_size=4, activation='relu', input_shape=(seq_length, 1)),
    MaxPooling1D(pool_size=4),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v13.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v13.fit(X_treino, y_treino, epochs=10, batch_size=1024, verbose=1)

# Avaliar o modelo
loss = modelo_v13.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v13.predict(X_teste)

# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

```
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

38/38 ————— 1s 8ms/step - loss: 0.1420

Epoch 2/10

38/38 ————— 0s 6ms/step - loss: 0.0637

Epoch 3/10

38/38 ————— 0s 6ms/step - loss: 0.0553

Epoch 4/10

38/38 ————— 0s 6ms/step - loss: 0.0515

Epoch 5/10

38/38 ————— 0s 6ms/step - loss: 0.0478

Epoch 6/10

38/38 ————— 0s 5ms/step - loss: 0.0432

Epoch 7/10

38/38 ————— 0s 6ms/step - loss: 0.0395

Epoch 8/10

38/38 ————— 0s 6ms/step - loss: 0.0369

Epoch 9/10

38/38 ————— 0s 7ms/step - loss: 0.0355


Epoch 10/10

38/38 ————— 0s 5ms/step - loss: 0.0345

302/302 ————— 1s 2ms/step - loss: 0.0272

Loss: 0.027661213651299477

302/302 ————— 1s 2ms/step



```
In [159... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_true_reformulado
y_pred_reformulado = y_pred.squeeze() # Remove a dimensão extra de y_pred

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_13 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_13)
# Calcular o RMSE
rmse_13 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_13)

MAE: 0.2820397868846037
RMSE: 0.33939741550522284
```

```
In [160... # após testes, verificou-se que o melhor batch_size é 32. Valores maiores diminuem
```

8.12.4 - Otimização alterando o epochs

```
In [161... # Normalização dos dados
scaler = MinMaxScaler()
df['traffic_volume_normalized'] = scaler.fit_transform(df[['traffic_volume']])

# Divisão dos dados em sequências
def create_sequences(data, seq_length):
    X, y = [], []
    for i in range(len(data) - seq_length):
        X.append(data[i:i+seq_length])
        y.append(data[i+seq_length])
    return np.array(X), np.array(y)

seq_length = 10 # ajuste conforme necessário
X, y = create_sequences(df['traffic_volume_normalized'].values, seq_length)

# Divisão dos dados em conjuntos de treinamento e teste
```

```

X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, shuffle=True)

# Redimensionamento dos dados para 3D
X_treino = np.reshape(X_treino, (X_treino.shape[0], X_treino.shape[1], 1))
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

# Construir o modelo 1D CNN
modelo_v14 = Sequential([
    Conv1D(filters=64, kernel_size=4, activation='relu', input_shape=(seq_length, 1)),
    MaxPooling1D(pool_size=4),
    Flatten(),
    Dense(64, activation='relu'),
    Dense(1)
])

# Compilar o modelo
modelo_v14.compile(optimizer='adam', loss='mean_squared_error')

# Treinar o modelo
modelo_v14.fit(X_treino, y_treino, epochs=10, batch_size=32, verbose=1)

# Avaliar o modelo
loss = modelo_v14.evaluate(X_teste, y_teste)
print("Loss:", loss)

# Fazer previsões
y_pred = modelo_v14.predict(X_teste)

# Visualizar os resultados
plt.plot(X_teste[:,0], y_teste, label='Real')
plt.plot(X_teste[:,0], y_pred, label='Previsões')
plt.legend()
plt.show()

```

Epoch 1/10

C:\Users\Chilov\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.

super().__init__(activity_regularizer=activity_regularizer, **kwargs)

1205/1205 ————— 6s 4ms/step - loss: 0.0665

Epoch 2/10

1205/1205 ————— 4s 3ms/step - loss: 0.0319

Epoch 3/10

1205/1205 ————— 3s 3ms/step - loss: 0.0276

Epoch 4/10

1205/1205 ————— 3s 3ms/step - loss: 0.0267

Epoch 5/10

1205/1205 ————— 4s 3ms/step - loss: 0.0254

Epoch 6/10

1205/1205 ————— 3s 3ms/step - loss: 0.0254

Epoch 7/10

1205/1205 ————— 3s 3ms/step - loss: 0.0247

Epoch 8/10

1205/1205 ————— 4s 4ms/step - loss: 0.0242

Epoch 9/10

1205/1205 ————— 3s 3ms/step - loss: 0.0237

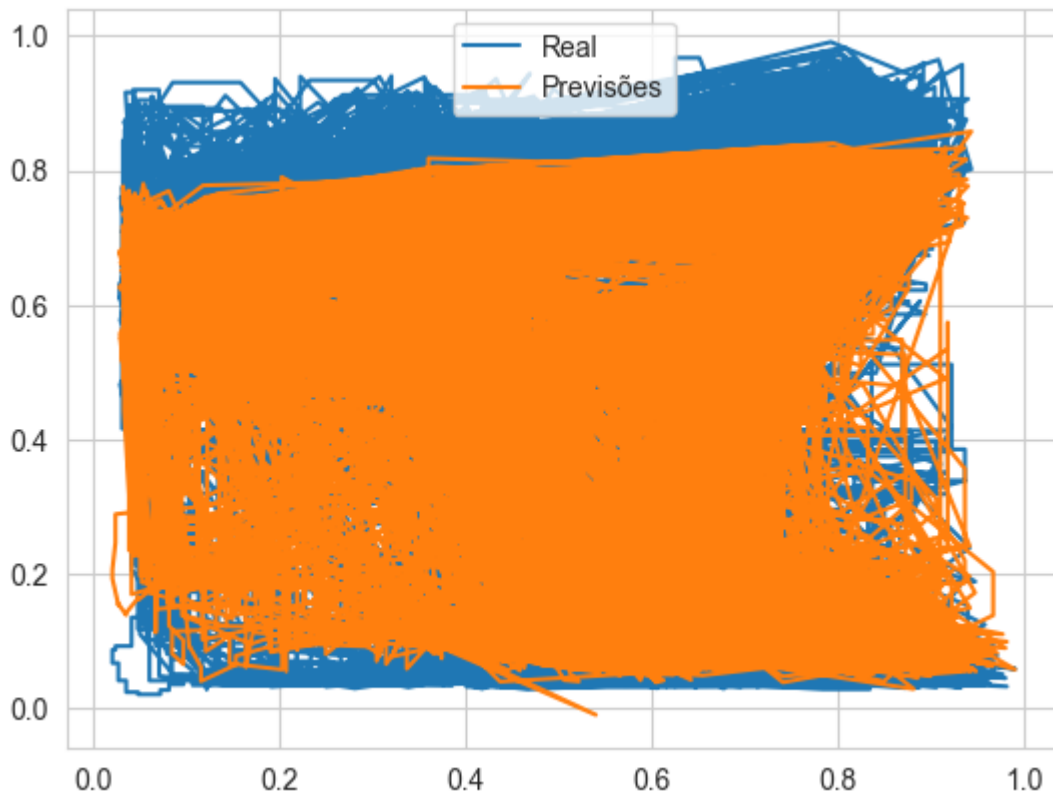
Epoch 10/10

1205/1205 ————— 4s 3ms/step - loss: 0.0236

302/302 ————— 1s 2ms/step - loss: 0.0166

Loss: 0.016079220920801163

302/302 ————— 1s 2ms/step



```
In [162... #redimensionando y
y_reformulado = y[:len(y_pred)]
# Redimensionar y_pred para ter a mesma forma que y_true_reformulado
y_pred_reformulado = y_pred.squeeze() # Remove a dimensão extra de y_pred

# Supondo que `y_true` são os valores reais e `y_pred` são as previsões do modelo
mae_14 = mean_absolute_error(y_reformulado, y_pred_reformulado)
print("MAE:", mae_14)
# Calcular o RMSE
rmse_14 = np.sqrt(mean_squared_error(y_reformulado, y_pred_reformulado))
print("RMSE:", rmse_14)

MAE: 0.29537572847584115
RMSE: 0.3581548739002708
```

```
In [163... # após testes, verificou-se que o melhor epochs é 10.
```

```
In [164... # assim, utilizamos o modelo v_14 como final.
```

8.13 - Utilizando o modelo escolhido para previsões futuras

```
In [165... # para finalizar vamos fazer a previsão do volume de tráfego para os próximos 6 meses
# Definir o número de dias para prever
dias_para_prever = 180

# Copiar o último conjunto de dados de teste para iniciar a previsão
ultimo_x = X_teste[-1]

# Lista para armazenar as previsões
previsoes = []

# Fazer as previsões para os próximos dias
for _ in range(dias_para_prever):
```


```
# Prever o próximo ponto no tempo
proxima_predicao = modelo_v14.predict(ultimo_x.reshape(1, seq_length, 1))
# Adicionar a previsão à lista de previsões
previsoes.append(proxima_predicao[0, 0])
# Atualizar os dados de entrada para a próxima iteração, descartando o primeiro
ultimo_x = np.append(ultimo_x[1:, :], proxima_predicao, axis=0)

# Visualizar as previsões
plt.plot(y_teste, label='Real') # Plotar os últimos dados reais
plt.plot(range(len(y_teste), len(y_teste) + dias_para_prever), previsoes, label='Pr')
plt.legend()
plt.title('Previsão de Tráfego para os Próximos 180 Dias')
plt.xlabel('Dias')
plt.ylabel('Tráfego Normalizado')
plt.show()
```


1/1	0s	28ms/step
1/1	0s	29ms/step
1/1	0s	25ms/step
1/1	0s	22ms/step
1/1	0s	35ms/step
1/1	0s	37ms/step
1/1	0s	29ms/step
1/1	0s	25ms/step
1/1	0s	29ms/step
1/1	0s	34ms/step
1/1	0s	35ms/step
1/1	0s	21ms/step
1/1	0s	16ms/step
1/1	0s	28ms/step
1/1	0s	25ms/step
1/1	0s	27ms/step
1/1	0s	33ms/step
1/1	0s	25ms/step
1/1	0s	22ms/step
1/1	0s	22ms/step
1/1	0s	26ms/step
1/1	0s	18ms/step
1/1	0s	23ms/step
1/1	0s	17ms/step
1/1	0s	18ms/step
1/1	0s	24ms/step
1/1	0s	26ms/step
1/1	0s	27ms/step
1/1	0s	25ms/step
1/1	0s	23ms/step
1/1	0s	30ms/step
1/1	0s	22ms/step
1/1	0s	19ms/step
1/1	0s	25ms/step
1/1	0s	24ms/step
1/1	0s	23ms/step
1/1	0s	21ms/step
1/1	0s	27ms/step
1/1	0s	20ms/step
1/1	0s	25ms/step
1/1	0s	26ms/step
1/1	0s	30ms/step
1/1	0s	34ms/step
1/1	0s	22ms/step
1/1	0s	20ms/step
1/1	0s	24ms/step
1/1	0s	25ms/step
1/1	0s	32ms/step
1/1	0s	30ms/step
1/1	0s	28ms/step
1/1	0s	25ms/step
1/1	0s	27ms/step
1/1	0s	24ms/step
1/1	0s	40ms/step
1/1	0s	26ms/step
1/1	0s	29ms/step
1/1	0s	42ms/step
1/1	0s	33ms/step
1/1	0s	50ms/step
1/1	0s	43ms/step
1/1	0s	23ms/step
1/1	0s	22ms/step
1/1	0s	37ms/step
1/1	0s	30ms/step

1/1	0s	28ms/step
1/1	0s	24ms/step
1/1	0s	31ms/step
1/1	0s	30ms/step
1/1	0s	29ms/step
1/1	0s	24ms/step
1/1	0s	27ms/step
1/1	0s	46ms/step
1/1	0s	28ms/step
1/1	0s	31ms/step
1/1	0s	23ms/step
1/1	0s	29ms/step
1/1	0s	20ms/step
1/1	0s	27ms/step
1/1	0s	27ms/step
1/1	0s	25ms/step
1/1	0s	25ms/step
1/1	0s	30ms/step
1/1	0s	27ms/step
1/1	0s	30ms/step
1/1	0s	30ms/step
1/1	0s	22ms/step
1/1	0s	25ms/step
1/1	0s	24ms/step
1/1	0s	24ms/step
1/1	0s	27ms/step
1/1	0s	25ms/step
1/1	0s	24ms/step
1/1	0s	22ms/step
1/1	0s	25ms/step
1/1	0s	25ms/step
1/1	0s	23ms/step
1/1	0s	24ms/step
1/1	0s	30ms/step
1/1	0s	25ms/step
1/1	0s	27ms/step
1/1	0s	24ms/step
1/1	0s	23ms/step
1/1	0s	23ms/step
1/1	0s	27ms/step
1/1	0s	26ms/step
1/1	0s	24ms/step
1/1	0s	31ms/step
1/1	0s	27ms/step
1/1	0s	25ms/step
1/1	0s	24ms/step
1/1	0s	22ms/step
1/1	0s	23ms/step
1/1	0s	28ms/step
1/1	0s	21ms/step
1/1	0s	29ms/step
1/1	0s	24ms/step
1/1	0s	23ms/step
1/1	0s	23ms/step
1/1	0s	22ms/step
1/1	0s	20ms/step
1/1	0s	23ms/step
1/1	0s	25ms/step
1/1	0s	20ms/step
1/1	0s	26ms/step
1/1	0s	23ms/step
1/1	0s	21ms/step
1/1	0s	28ms/step
1/1	0s	22ms/step

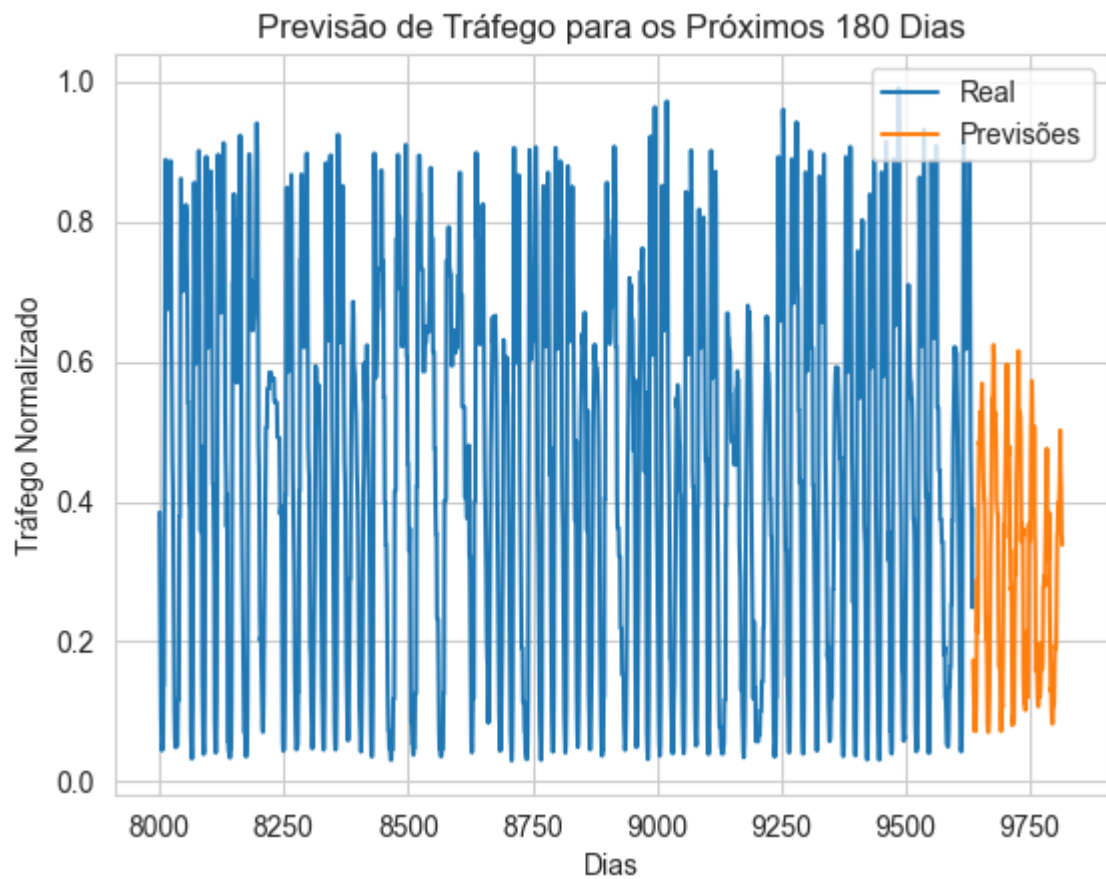
1/1		0s	23ms/step
1/1		0s	17ms/step
1/1		0s	27ms/step
1/1		0s	19ms/step
1/1		0s	23ms/step
1/1		0s	19ms/step
1/1		0s	26ms/step
1/1		0s	19ms/step
1/1		0s	22ms/step
1/1		0s	23ms/step
1/1		0s	24ms/step
1/1		0s	22ms/step
1/1		0s	14ms/step
1/1		0s	23ms/step
1/1		0s	22ms/step
1/1		0s	23ms/step
1/1		0s	22ms/step
1/1		0s	23ms/step
1/1		0s	17ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step
1/1		0s	25ms/step
1/1		0s	24ms/step
1/1		0s	22ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step
1/1		0s	26ms/step
1/1		0s	19ms/step
1/1		0s	22ms/step
1/1		0s	22ms/step
1/1		0s	22ms/step
1/1		0s	22ms/step
1/1		0s	17ms/step
1/1		0s	22ms/step
1/1		0s	22ms/step
1/1		0s	17ms/step
1/1		0s	23ms/step
1/1		0s	20ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step
1/1		0s	22ms/step
1/1		0s	19ms/step
1/1		0s	24ms/step
1/1		0s	19ms/step
1/1		0s	20ms/step
1/1		0s	25ms/step
1/1		0s	29ms/step
1/1		0s	20ms/step
1/1		0s	23ms/step
1/1		0s	23ms/step



In [166... *#como a visualização está ruim, vamos observar apenas os últimos 2000 dias e os 60 r*

```
In [167... # Ajustar os índices para plotar apenas a partir de 8000
inicio = 8000
fim = inicio + dias_para_prever

# Visualizar as previsões
plt.plot(range(inicio, len(y_teste)), y_teste[inicio:], label='Real') # Plotar os
plt.plot(range(len(y_teste), len(y_teste) + dias_para_prever), previsoes, label='Pr
plt.legend()
plt.title('Previsão de Tráfego para os Próximos 180 Dias')
plt.xlabel('Dias')
plt.ylabel('Tráfego Normalizado')
plt.show()
```



Conclusão

O melhor modelo foi o v14 com RMSE de apenas 0.359.

Fim